

## Paper: IA, Human Cognition and Knowledge Collapse

Derivación: Observación 1 y efecto ambiguo de la precisión de la IA

$$U_{i,t} = f(0,0) + G(x_t)\Delta G + G(x_t)G(y_{i,t})\Delta x - \frac{1}{\alpha} e_{i,t}^{\alpha} \quad \alpha > 1$$

$$y_{i,t} = \sigma^{-2} + \lambda_I e_{i,t} + \tau_A$$

$$G(\tau) = \Pr(|z| \leq 1) = 2\Phi(\sqrt{\tau}) - 1 \quad g(\tau) = G'(\tau) = \frac{\phi(\sqrt{\tau})}{\sqrt{\tau}}$$

$$\text{como: } g(\tau) = \frac{1}{\sqrt{2\pi}} \tau^{-\frac{1}{2}} e^{-\frac{\tau}{2}} \rightarrow g'(\tau) = g(\tau) \left(-\frac{1}{2} - \frac{1}{2\tau}\right) < 0$$

$$\circ^{\circ} \quad g(\tau) > 0, \quad g'(\tau) < 0$$

1. Beneficio marginal del esfuerzo

\*El término de  $U_{i,t}$  que depende directamente de  $e_{i,t}$  es  $G(x_t)G(y_{i,t})\Delta x - \frac{1}{\alpha} e_{i,t}^{\alpha}$

$$\text{Como } \frac{\partial U_{i,t}}{\partial e_{i,t}} = \lambda_I \rightarrow \frac{\partial U_{i,t}}{\partial e_{i,t}} = G(x_t)\Delta x \frac{\partial G(y_{i,t})}{\partial e_{i,t}} - e_{i,t}^{\alpha-1}$$

$$\frac{\partial G(y_{i,t})}{\partial e_{i,t}} = G'(y_{i,t}) \frac{\partial y_{i,t}}{\partial e_{i,t}} = g(y_{i,t})\lambda_I$$

$$\frac{\partial U_{i,t}}{\partial e_{i,t}} = \Delta x G(x_t) \lambda_I g(y_{i,t}) - e_{i,t}^{\alpha-1}$$

2. Conocimiento general como complemento del esfuerzo

$$\frac{\partial^2 U_{i,t}}{\partial e_{i,t} \partial x_t} = \frac{\partial (\Delta x G(x_t) \lambda_I g(y_{i,t}) - e_{i,t}^{\alpha-1})}{\partial x_t}$$

$$\frac{\partial^2 U_{i,t}}{\partial e_{i,t} \partial x_t} = \Delta x \lambda_I g(y_{i,t}) G'(x_t)$$

$$\text{Usando } G'(x_t) = g(x_t) \rightarrow \frac{\partial^2 U_{i,t}}{\partial e_{i,t} \partial x_t} = \underbrace{\Delta x}_{+} \underbrace{\lambda_I}_{+} \underbrace{g(x_t)}_{+} \underbrace{g(y_{i,t})}_{+} > 0$$

$\rightarrow x$  complementa el esfuerzo humano

3. IA Agéntica como sustituto del esfuerzo

$$\frac{\partial^2 U_{i,t}}{\partial e_{i,t} \partial \tau_A} = \frac{\partial (\Delta x G(x_t) \lambda_I g(y_{i,t}) - e_{i,t}^{\alpha-1})}{\partial \tau_A}$$

$$\text{dado que } \frac{\partial y_{i,t}}{\partial T_A} = 1 \rightarrow \frac{\partial g(y_{i,t})}{\partial T_A} = g'(y_{i,t}) \frac{\partial y_{i,t}}{\partial T_A} = g'(y_{i,t})$$

$$\rightarrow \frac{\partial^2 \mathcal{U}_{i,t}}{\partial e_{i,t} \partial T_A} = \underbrace{\Delta x}_{+} \underbrace{G(x_t)}_{+} \underbrace{\lambda_I}_{+} \underbrace{g'(y_{i,t})}_{-} < 0$$

$\rightarrow T_A$  sustituye el esfuerzo humano

4. Implicación sobre el esfuerzo óptimo

Condición de primer orden del  $\mathcal{L}$ :

$$\Delta x G(x_t) \lambda_I g(y_{i,t}) - e_{i,t}^{\alpha-1} = 0$$

$$H(e_{i,t}, x_t, T_A) = \Delta x G(x_t) \lambda_I g(y_{i,t}) - e_{i,t}^{\alpha-1}$$

$$H_e = \Delta x G(x_t) \lambda_I^2 g'(y_{i,t}) - (\alpha-1) e_{i,t}^{\alpha-2} < 0$$

$$H_x = \Delta x \lambda_I g(x_t) g(y_{i,t}) > 0$$

$$H_{T_A} = \Delta x G(x_t) \lambda_I g'(y_{i,t}) < 0$$

por el teorema de la función implícita:  $\frac{\partial e^*}{\partial x_t} = -\frac{H_x}{H_e} > 0$

$$\frac{\partial e^*}{\partial T_A} = -\frac{H_{T_A}}{H_e} < 0$$

Así:  $\uparrow x_t : \uparrow e^*$ , pero  $\uparrow T_A : \downarrow e^*$

5. Precisión de la IA y bienestar

En el estado estacionario alto, el bienestar puede escribirse como

$$\bar{U}^+ = G(\bar{x}_h) \Delta G + G(\bar{x}_h) G(\bar{y}_h) \Delta x - \frac{1}{\alpha} e_h^{-\alpha}$$

donde:  $\bar{y}_h = \sigma^{-2} + \lambda_I \bar{e}_h + T_A$

Equivalente:  $\bar{U}(x, T_A) = G(x) \Delta G + \max_{e \geq 0} \left\{ G(x) G(\sigma^{-2} + \lambda_I e + T_A) \Delta x - \frac{1}{\alpha} e^\alpha \right\}$

Sea  $\bar{U}^+(T_A) = \bar{U}(\bar{x}_h(T_A), T_A)$

por el teorema de la envuelta:  $\frac{\partial \bar{U}}{\partial T_A} = G(x) \Delta x g(y)$

Además,  $\frac{\partial \bar{U}}{\partial x} = g(x) [\Delta G + G(y) \Delta x]$

$$\longrightarrow \frac{d \bar{U}^+}{d T_A} = \frac{\partial \bar{U}}{\partial T_A} + \frac{\partial \bar{U}}{\partial x} \frac{d \bar{x}_h}{d T_A}$$

Evaluando en el SS alto:

$$\frac{d\bar{U}^+}{dT_A} = \underbrace{G(\bar{X}_h)\Delta x g(\bar{Y}_h)}_{\text{efecto directo} > 0} + \underbrace{g(\bar{X}_h)[\Delta G + G(\bar{Y}_h)\Delta x]}_{\text{efecto indirecto} < 0} \frac{d\bar{X}_h}{dT_A}$$

Como la IA agéntica reduce el esfuerzo humano:  $\frac{d\bar{X}_h}{dT_A} < 0$

Por lo tanto:  $G(\bar{X}_h)\Delta x g(\bar{Y}_h) > 0 \rightarrow$  representa que una IA más precisa mejora la información específica del agente

- pero  $g(\bar{X}_h)[\Delta G + G(\bar{Y}_h)\Delta x] \frac{d\bar{X}_h}{dT_A} < 0 \rightarrow$  representa que una IA más precisa reduce el esfuerzo humano y debilita el conocimiento general

Así  $\frac{d\bar{U}^+}{dT_A} \geq 0 \rightarrow$  El bienestar no necesariamente aumenta con la precisión de la IA