
IA, cognición humana y colapso del conocimiento

Repositorio 4 - Modelo, resultado y lectura crítica

Isis Roque

NBER Working Paper No. 34910 - febrero de 2026

github.com/isisroquet-mi/ai-04-acemoglu

El artículo y el problema del agente

Pregunta

¿La IA agéntica mejora las decisiones presentes a costa del aprendizaje humano que sostiene el conocimiento colectivo?

Elección privada

$$\max_{e_{i,t} \geq 0} U_{i,t} = f(0,0) + G(X_t)\Delta_G + G(X_t)G(Y_{i,t})\Delta_X - \frac{e_{i,t}^\alpha}{\alpha}, \quad \alpha > 1.$$

$$Y_{i,t} = \sigma^{-2} + \lambda_I e_{i,t} + \tau_A.$$

Externalidad: el agente internaliza el beneficio privado de aprender, pero no el aporte de su señal al conocimiento de cohortes futuras.

Dos conocimientos

- X_t : conocimiento general heredado y compartido.
- $Y_{i,t}$: información específica del contexto.
- $e_{i,t}$ produce una señal privada y una señal pública “delgada”.

Resultado principal y condiciones

Tensión estática: Observación 1

$$\frac{\partial U}{\partial e} = \Delta_X G(X) \lambda_I g(Y) - e^{\alpha-1}.$$

$$\frac{\partial^2 U}{\partial e \partial X} = \Delta_X \lambda_I g(X) g(Y) > 0,$$

$$\frac{\partial^2 U}{\partial e \partial \tau_A} = \Delta_X G(X) \lambda_I g'(Y) < 0.$$

Condiciones: $\Delta_X > 0$, $\lambda_I > 0$, $g > 0$, $g' < 0$ y costo convexo $\alpha > 1$. Así, e^* aumenta con X y disminuye con τ_A .

Dinámica: cuándo aparece el colapso

- Si $\alpha - 1 > \frac{1}{4}$ ($\varepsilon < 4$), todo $X_1 > 0$ converge al único estado estable de conocimiento alto $\bar{X}_h > 0$.
- Si $\alpha - 1 < \frac{1}{4}$ ($\varepsilon > 4$) y $\tau_A < \tau_A^c$, existen $0 < \bar{X}_m < \bar{X}_h$: $X_1 < \bar{X}_m$ converge a 0 y $X_1 > \bar{X}_m$ converge a $\bar{X}_h$.
- Si $\alpha - 1 < \frac{1}{4}$ y $\tau_A > \tau_A^c$, $\bar{X} = 0$ es el único estado estacionario y es globalmente estable.

El paper usa desigualdades estrictas. El caso frontera $\alpha - 1 = \frac{1}{4}$ y la igualdad $\tau_A = \tau_A^c$ no forman parte de estas proposiciones.

Lo que hice

Lectura y verificación

- Trabajé con el NBER Working Paper No. 34910, febrero de 2026, 69 páginas y no revisado por pares.
- Lo contrasté con la versión del 5 de mayo de 2026: mismo título, autores, 69 páginas y argumento central. Cambia la portada, la redacción y la parametrización $\alpha - 1$ frente a $\varepsilon = 1/(\alpha - 1)$.
- Derivé la Observación 1 y separé el efecto directo e indirecto de τ_A sobre el bienestar.

Qué demuestra y qué supone

Demostrado dentro del modelo

La IA agéntica reduce el retorno marginal del esfuerzo. Bajo las condiciones de elasticidad y precisión, puede eliminar el equilibrio de conocimiento alto.

Dependencia crítica de supuestos

La Sección 5 relaja agregación, datos sintéticos y separabilidad imperfecta, pero mantiene $\Delta_I = 0$ y $\Delta_X > 0$. Con $\Delta_I > 0$, la información específica podría conservar valor aun con poco conocimiento general.

Dónde no creí en la IA

La intuición que puse a prueba

“Más precisión de la IA siempre aumenta el bienestar.”

$$\frac{d\bar{U}^+}{d\tau_A} = \underbrace{G(\bar{X}_h)\Delta_X g(\bar{Y}_h)}_{\text{directo} > 0} + \underbrace{g(\bar{X}_h) [\Delta_G + G(\bar{Y}_h)\Delta_X]}_{\text{indirecto} < 0} \frac{d\bar{X}_h}{d\tau_A}.$$

Con el Supuesto 2, $\sigma^{-2} \geq \sqrt{2} - 1$, $\bar{U}^+(\tau_A)$ tiene un pico único.

Veredicto: incompleta. El efecto indirecto puede dominar.

Evaluar en el SS alto:

$$\frac{d\bar{U}^+}{d\tau_A} = \underbrace{G(\bar{X}_h)\Delta_X g(\bar{Y}_h)}_{\text{efecto directo} > 0} + \underbrace{g(\bar{X}_h) [\Delta_G + G(\bar{Y}_h)\Delta_X]}_{\text{efecto indirecto} < 0} \frac{d\bar{X}_h}{d\tau_A}$$

Como la IA agéntica reduce el esfuerzo humano: $\frac{d\bar{X}_h}{d\tau_A} < 0$

Por lo tanto: $G(\bar{X}_h)\Delta_X g(\bar{Y}_h) > 0 \rightarrow$ representa que una IA más precisa mejora la información específica del agente

pero $g(\bar{X}_h) [\Delta_G + G(\bar{Y}_h)\Delta_X] \frac{d\bar{X}_h}{d\tau_A} < 0 \rightarrow$ representa que una IA más precisa reduce el esfuerzo humano y debilita el conocimiento general


Así $\frac{d\bar{U}^+}{d\tau_A} \geq 0 \rightarrow$ El bienestar no necesariamente aumenta con la prec de la IA

Derivación manual de Isis Roque, p. 3: efecto directo > 0 e indirecto < 0 .


Dinámica: el papel de α

Los estados estacionarios aparecen donde $F(X)$ corta la línea de 45 grados. Se fija $\tau_A = 0.48$ y se modifica únicamente α . El panel derecho amplía la región de los tres cruces.

$\alpha = 1.50$: único cruce positivo




$\alpha = 1.20$: tres cruces



Con $\alpha = 1.20$, los cruces son $\bar{X}_\ell = 0$, $\bar{X}_m \approx 0.060$ y $\bar{X}_h \approx 0.302$. El punto intermedio separa las dos cuencas de atracción.

Simulación ilustrativa: $\Delta_X = 6$, $\lambda_I = I = \Sigma^2 = 1$, $\lambda_G = 2$ y $\sigma^{-2} = 0.5$.

Umbral de colapso



Cambio en $F(X)$

Se mantiene $\alpha = 1.20$. Un aumento de τ_A reduce el esfuerzo humano y desplaza $F(X)$ hacia abajo.


$$\tau_A^c \approx 0.526, \quad \bar{X}^c \approx 0.163.$$

$\tau_A < \tau_A^c$: dos equilibrios positivos.

$\tau_A = \tau_A^c$: los dos se unen por tangencia.

$\tau_A > \tau_A^c$: solo permanece $\bar{X} = 0$.

Dependencia de la condición inicial



Con $\alpha = 1.20$ y $\tau_A = 0.48$ existen tres estados estacionarios:

$$\bar{X}_m \approx 0.0599,$$

$$\bar{X}_h \approx 0.3018.$$

- $X_1 = 0.04$ cae gradualmente hacia 0.
- $X_1 = 0.08$ converge hacia $\bar{X}_h$.

El umbral separa dos cuencas de atracción. Una diferencia inicial de 0.04 cambia el resultado de largo plazo.

Lean: traducción de la Observación 1

Ecuación original

$$M(\tau_A) = \Delta_X G(X) \lambda_I g(\sigma^{-2} + \lambda_I e + \tau_A) - c'(e),$$

$$\frac{\partial M}{\partial \tau_A} = \Delta_X G(X) \lambda_I g'(Y) < 0$$

Lean representa el lado derecho con `aiPrecisionCrossPartial` y verifica su signo. La igualdad con la derivada cruzada se toma de la traducción del paper.

Objetos y supuestos

- `deltaX`: complementariedad $\Delta_X > 0$.
- `generalKnowledgeValue`: valor evaluado $G(X) > 0$.
- `signalProductivity`: $\lambda_I > 0$.
- `gPrime`: valor evaluado $g'(Y)$.
- `hgPrime_neg`: supuesto $g'(Y) < 0$.

Conclusión formal

La expresión `aiPrecisionCrossPartial` es estrictamente negativa bajo esos supuestos.

Lean: prueba verificada

Paso no trivial

have hCoefficient :

$0 < p.\text{deltaX} * p.\text{generalKnowledgeValue} *$

$p.\text{signalProductivity} :=$

$\text{mul_pos } (\text{mul_pos } p.\text{deltaX_pos}$

$p.\text{generalKnowledgeValue_pos})$

$p.\text{signalProductivity_pos}$

$\text{exact mul_neg_of_pos_of_neg}$

$\text{hCoefficient hgPrime_neg}$

aiPrecisionCrossPartial representa los cuatro factores de la fórmula. El fragmento prueba que los tres primeros forman un coeficiente positivo y luego usa $g'(Y) < 0$.

Qué comprobó Lean

- La traducción conserva los cuatro factores de la fórmula.
- El producto tiene signo negativo bajo las hipótesis visibles.
- El endpoint prueba exactamente la Spec, sin sorry ni axiomas añadidos.

Límite de la prueba

No deriva la fórmula desde U , ni verifica el umbral global τ_A^C , la estabilidad o la no monotonicidad completa del bienestar.

lake build AKO26KnowledgeCollapse